

TALENTO ALTAMENTE ESPECIALIZADO

Inteligencia Artificial 2026 COCYTEN–Nayarit

MÓDULO 6 · DEEP LEARNING

MediaScope IA

Sistema multimodal para análisis integrado y narración de imagen y audio

VISIÓN

AUDIO

TEXTO

VOZ

Estudiantes

Ricardo Torres López

Cesar Eduardo Inda Cenicerros

Profesor: Dr. Francisco Rodriguez Navarrete

Fecha de asignación: 17/09/2026 · **Fecha de entrega:** 26/09/2026

Contenido

- | | |
|----|--|
| 1 | Resumen |
| 2 | Arquitectura y diagrama del pipeline |
| 3 | Modelos utilizados y justificación |
| 4 | Implementación y decisiones técnicas |
| 5 | Resultados y ejemplos reales |
| 6 | Casos de falla documentados |
| 7 | Ética, guardrails y riesgos pendientes |
| 8 | Reproducibilidad |
| 9 | Conclusiones |
| 10 | Referencias |

Alcance del documento

Este reporte describe la revisión final MediaScope Etapa 7 (final-r2), ejecutada en Windows con una GPU NVIDIA GeForce RTX 4070 Laptop de 8 GB. Los tiempos corresponden a pruebas reales y pueden variar entre la primera inferencia y ejecuciones posteriores.


1. Resumen

MediaScope IA es una aplicación web multimodal desarrollada con Gradio que recibe una imagen, una grabación de audio o ambas entradas; analiza la imagen con YOLO11n para detectar y localizar objetos y con BLIP para generar una descripción contextual; procesa el audio con Whisper para transcribir el habla y con AST para clasificar eventos acústicos; integra los resultados mediante reglas deterministas y produce una imagen anotada, tablas de evidencia, un reporte técnico descargable y una narración en español generada con MMS-TTS. La aplicación funciona de manera condicional cuando falta una modalidad, emplea aceleración CUDA cuando está disponible y puede utilizarse desde un navegador local o mediante un enlace público temporal de Gradio.

Cumplimiento de entrada

La versión final cumple las tres condiciones obligatorias: integra dos modelos de visión con funciones distintas, incorpora modelos que analizan y generan audio, y se ejecuta en vivo desde una interfaz Gradio.

MediaScope — Pipeline multimodal



2. Arquitectura y diagrama del pipeline

La arquitectura es mixta y condicional. Es secuencial en la orquestación real: la función principal ejecuta primero la rama visual disponible, después la rama auditiva disponible, fusiona la evidencia y finalmente genera la narración. A la vez, las ramas son lógicamente independientes, porque cada modalidad tiene su propio preprocesamiento y sus propios modelos; no obstante, la implementación final no utiliza hilos ni inferencia simultánea. La lógica condicional permite entregar un reporte completo con imagen y audio, o un reporte parcial cuando solo existe una de las dos entradas.

MediaScope IA · pipeline implementado




Figura 1. Pipeline mixto y condicional implementado en MediaScope. Las ramas son independientes, pero app.py las orquesta en secuencia para controlar el consumo de VRAM.

2.1 Conexión entre etapas

Etapa	Entrada	Procesamiento	Salida	Conexión
Adquisición	Imagen JPG/PNG/cámara y/o audio WAV/MP3/micrófono	Gradio recibe controles y archivos	Objetos PIL y ruta temporal	Validación
Preprocesamiento visual	Imagen	Conversión RGB; YOLO redimensiona a 640 px; BLIP aplica su procesador	Tensor/imagen preparada	YOLO11n y BLIP
Detección	Imagen RGB	YOLO11n con umbral configurable	Cajas, clases, cantidades y confianza	Fusión
Descripción	Imagen RGB	BLIP base; beam search sin muestreo	Caption contextual	Fusión
Preprocesamiento auditivo	WAV/MP3	Librosa: mono, 16 kHz, máximo 30 s	Forma de onda float32	Whisper y AST
Transcripción	Forma de onda	Whisper base; idioma automático/es/en	Texto reconocido	Fusión
Clasificación acústica	Segmentos de hasta 10 s	AST; top 3 por intervalo	Eventos y puntuaciones	Fusión
Fusión	Salidas disponibles	Reglas, traducción de etiquetas y advertencias	Reporte integrado	MMS-TTS y exportador
Narración	Texto limpio ≤ 900 caracteres	MMS-TTS por fragmentos	WAV en español	Gradio
Presentación	Resultados	Tabs, tablas, reproductor y archivo .md	Salidas visuales, textuales y auditivas	Usuario

2.2 Rutas condicionales

- Imagen + audio: ejecuta YOLO11n, BLIP, Whisper y AST; fusiona ambas evidencias y narra el reporte completo.
- Solo imagen: ejecuta YOLO11n y BLIP; reporta que no hubo audio y genera una narración basada únicamente en evidencia visual.
- Solo audio: ejecuta Whisper y AST; reporta que no hubo imagen y genera una narración basada únicamente en evidencia auditiva.
- Sin entradas: detiene el pipeline antes de cargar modelos y muestra el mensaje «Carga al menos una imagen o un audio para continuar».

3. Modelos utilizados y justificación

Los cinco checkpoints se eligieron para equilibrar cobertura funcional, calidad y consumo de memoria en una GPU de 8 GB. Los tamaños de checkpoint y parámetros provienen de la documentación y fichas oficiales; la VRAM es una estimación incremental de inferencia para esta configuración. Puede variar aproximadamente ± 30 % por versión de CUDA, resolución, longitud del audio y memoria reservada por PyTorch.

Modelo	Función	Parámetros	Checkpoint	VRAM estimada	Razón principal
YOLO11n	Detección visual	2.6 M	5.4 MB	$\approx 0.3\text{--}0.6$ GB	Rápido y ligero; 80 clases COCO
BLIP image-captioning base	Descripción visual	≈ 247 M*	990 MB F32	$\approx 1.0\text{--}1.5$ GB FP16	Captioning útil sin el costo de BLIP-large/BLIP-2
Whisper base	ASR multilingüe	74 M	290 MB F32	$\approx 0.8\text{--}1.2$ GB FP16	Mejor balance que tiny; menor costo que small/large
AST AudioSet	Clasificación acústica	86.6 M	346 MB F32	$\approx 0.6\text{--}1.0$ GB FP16	Reconoce eventos, no solo voz
MMS-TTS spa	Síntesis de voz	36.3 M	145 MB F32	$\approx 0.4\text{--}0.8$ GB	Voz española local, sin servicio externo

*El número de parámetros de BLIP base se aproxima a partir del checkpoint F32 de 990 MB; el valor exacto depende de la serialización y de los buffers incluidos.

3.1 Decisión modelo por modelo

YOLO11n. Se eligió la variante nano porque ofrece detección en tiempo real, produce cajas y confianzas directamente y deja memoria disponible para los demás modelos. YOLO11s/m pueden mejorar precisión, pero elevan latencia y VRAM sin aportar una función nueva al requisito.

BLIP base. Complementa a YOLO: describe el contexto global en lenguaje natural. Se prefirió a BLIP-large y BLIP-2 porque el checkpoint base cabe con holgura en 8 GB y su latencia observada fue menor a un segundo después de cargar el modelo.

Whisper base. La variante multilingüe soporta español e inglés y conserva un tamaño manejable. Whisper-tiny consume menos, pero suele perder más palabras; small, medium y large aumentan el costo sin ser necesarios para una demostración de 30 segundos.

AST. Aporta una tarea auditiva distinta de la transcripción: clasifica música, habla y sonidos ambientales con etiquetas de AudioSet. Un simple detector de voz no habría cubierto la diversidad acústica ni habría permitido advertir que la música afectaba a Whisper.

MMS-TTS spa. Genera la salida narrada en español de forma local y reproducible. Se evitó depender de una API de pago o credenciales. Su licencia CC BY-NC 4.0 es adecuada para la demostración académica, pero restringe el uso comercial.

3.2 Evidencia de cumplimiento de los requisitos

Condición	Evidencia en MediaScope	Resultado verificable
Requisito 1: dos modelos de visión	YOLO11n detecta/localiza; BLIP genera una descripción contextual. Son arquitecturas y tareas distintas.	Imagen anotada, tabla de objetos y caption.
Requisito 2: audio en el pipeline	Whisper analiza habla, AST analiza eventos acústicos y MMS-TTS genera narración.	Transcripción, tabla por intervalos y archivo WAV.

Condición	Evidencia en MediaScope	Resultado verificable
Requisito 3: aplicación Gradio en vivo	Interfaz con carga/captura, controles, ejecución y resultados interactivos.	URL local y enlace público temporal probados desde un celular.

4. Implementación y decisiones técnicas

4.1 Entorno validado

Componente	Configuración utilizada
Equipo	Dell G16; NVIDIA GeForce RTX 4070 Laptop GPU, 8 GB VRAM
Sistema	Windows; PowerShell; ejecución local en puerto 7860
Python	3.12 en entorno virtual .venv
PyTorch	2.14.0+cu130; CUDA disponible: True
Interfaz	Gradio; URL local y share link temporal
Versión del proyecto	MediaScope Etapa 7, release final-r2

4.2 Manejo de memoria y rendimiento

- Carga perezosa y caché: cada modelo se crea en su primera inferencia y se reutiliza en solicitudes posteriores; evita recargar cientos de MB en cada clic.
- Precisión mixta: BLIP, Whisper y AST usan float16 en CUDA y float32 en CPU; la selección es automática mediante `torch.cuda.is_available()`.
- Inferencia sin gradientes: `torch.inference_mode()` reduce memoria y sobrecarga en BLIP, Whisper y MMS-TTS.
- Cola limitada: Gradio usa `default_concurrency_limit=1` y `max_size=20` para evitar que varias inferencias simultáneas agoten la VRAM.
- Fallback: si CUDA no está disponible, los modelos se ejecutan en CPU; será más lento, pero el pipeline conserva su funcionalidad.
- Control de longitud: se procesan como máximo 30 s de audio y el texto narrable se recorta a 900 caracteres; MMS-TTS divide el texto en bloques de 230 caracteres.

4.3 Formatos y preprocesamiento

Modalidad	Entrada	Transformación	Motivo
Imagen	PIL desde archivo/cámara/portapapeles	RGB; YOLO imgsz=640; BLIP usa su procesador	Compatibilidad y costo controlado
Audio	Ruta WAV/MP3 u otro formato decodificable	Librosa → mono, 16 kHz, float32, máximo 30 s	Formato común para Whisper y AST
AST	Forma de onda a 16 kHz	Segmentos consecutivos de hasta 10 s; top 3	Conservar contexto temporal
Salida narrada	Texto fusionado	Limpieza de Markdown; fragmentos; silencios de 0.18 s	Evitar secuencias demasiado largas
Exportación	Resultados y metadatos	Markdown con tiempos, modelos y dispositivos	Trazabilidad y descarga simple

4.4 Fusión y control de afirmaciones

La fusión no utiliza un modelo generativo adicional. Se implementó con reglas y plantillas controladas que toman solamente objetos, caption, transcripción y etiquetas acústicas producidas por los modelos. También traduce clases frecuentes al español, consolida etiquetas acústicas equivalentes —por ejemplo, Music y Pop music— y agrega una advertencia cuando AST determina que la música domina, porque en ese caso la transcripción de Whisper puede ser poco confiable.

4.5 Problemas técnicos resueltos

Problema observado	Resolución aplicada
PyTorch se desinstaló al intentar cambiar de CPU a CUDA y se concatenaron dos comandos.	Se ejecutó una sola instrucción válida y se instaló torch 2.14.0+cu130 con torchvision 0.29.0.
torchaudio 2.14.0 no estaba disponible en el índice cu130.	Se eliminó esa dependencia; la decodificación y el remuestreo se realizan con Librosa y SoundFile.
Etiquetas de AST aparecían duplicadas como Music/Pop music.	La fusión conserva la confianza mayor por concepto traducido.
La terminal mostró WinError 10054 al cerrar o perder un navegador.	Se trató como desconexión del cliente; la aplicación se mantuvo operativa y se recargó la sesión.
Resultados del teléfono no aparecían en la PC.	Se documentó que cada pestaña/navegador mantiene una sesión Gradio independiente; no es un error del modelo.
Advertencias deprecadas de Transformers/Gradio.	Se confirmaron como advertencias no bloqueantes; deben atenderse al actualizar dependencias.

5. Resultados y ejemplos reales

Las pruebas se realizaron con un umbral de detección de 35 %. La imagen principal fue una portada de TIME de 2363 × 3150 píxeles y el audio fue un MP3 de 19.6 segundos con música dominante. Los tiempos son los reportados por la aplicación y no incluyen necesariamente la descarga inicial de checkpoints.

identifica los sonidos ambientales y TIME-S-TS narra en español el reporte multimodal integrado, que también puede descargarse con s

75%

1. Entradas

Imagen de entrada



Audio de entrada (recomendado: máximo 30 s)



0:09 0:20

Tipo de reporte

Detallado

Confianza mínima

0.35

Idioma del audio

Automático, español o inglés

Automático

Recomendación para la demostración

Analizar y narrar

Limpiar

2. Resultados

MediaScope final listo

Análisis multimodal completo. Análisis con YOLO11n y BLIP terminado: 7 objeto(s) y una descripción generada. Audio procesado con Whisper y AST (19.6 s). Reporte fusionado y narración generada (39.6 s).

Análisis visual

Análisis auditivo

Reporte multimodal

Detalles técnicos

Reporte multimodal integrado

Resumen

En la imagen se detectaron 4 personas y 3 corbatas. En el audio se identificaron principalmente música (77%), Rhythm and blues (8%) y música (3%). La salida integra evidencia visual y auditiva.

Evidencia visual

- YOLO11n: YOLO11n detectó 7 objeto(s): 4 × person, 3 × tie.
- BLIP: Time magazine cover with a man in a suit and tie.
- Umbral de detección: 35%
- Tiempo YOLO: 131.6 ms
- Tiempo BLIP: 422.2 ms

Evidencia auditiva

- Whisper: Sleep, sleep in the mother's hatchin' New young party, I see drip, drip in the emeral snake, thank you, blue garrigan, quick, quick, my chauffeur, drove me back like a performer, I went straight, straight to dance and saw you
- AST: eventos dominantes: música (77%), Rhythm and blues (8%) y música (3%).
- Duración procesada: 19.6 s
- Tiempo Whisper: 519.8 ms
- Tiempo AST: 66.3 ms

Interpretación responsable

Los resultados son estimaciones automáticas. Las detecciones, la descripción, la transcripción y los eventos acústicos deben verificarse antes de utilizarlos en decisiones importantes.

Narración del reporte en español



Descargar reporte técnico (.md)

reporte_mediascope_20260923_101955_7e43e964.md

2.4 KB ↓

Figura 2. Ejecución multimodal completa en la interfaz final. La captura ilustra la estructura de resultados; los tiempos pueden variar entre ejecuciones.

5.1 Caso principal: imagen + audio

Componente	Salida real	Tiempo
YOLO11n	7 detecciones: 4 personas y 3 corbatas	933.3 ms
BLIP	“Time magazine cover with a man in a suit and tie.”	660.7 ms
Whisper	Transcripción en inglés; contenido poco confiable por música dominante	974.3 ms
AST	Música 77 %, R&B 8 % y Funk 2 %	113.9 ms
MMS-TTS	Narración del reporte integrado en español	39.4 s de audio generado

Interpretación del ejemplo

La visión fue consistente: YOLO contó personas y corbatas, y BLIP describió el contexto general. En cambio, Whisper produjo una transcripción difícil de validar porque el audio era musical; AST ayudó a explicar esa limitación y la aplicación añadió una advertencia de confiabilidad.

Imagen procesada



Objetos detectados



Objeto	Cantidad	Confianza
person	4	0.683
tie	3	0.502

Figura 3. Evidencia visual: imagen anotada y tabla de detecciones de YOLO11n.

5.2 Pruebas condicionales

Prueba	Entrada	Resultado	Métricas observadas
Solo imagen	Portada TIME; sin audio	7 objetos, caption, reporte visual parcial y narración	YOLO 201.9 ms; BLIP 599.2 ms; narración 12.2 s
Solo audio	MP3 de 19.6 s; sin imagen	Transcripción, eventos acústicos, reporte auditivo parcial y narración	Whisper 705.1 ms; AST 53.1 ms; narración 28.6 s

Prueba	Entrada	Resultado	Métricas observadas
Acceso remoto	Imagen cargada desde celular con datos móviles	La URL pública procesó la entrada y mostró el reporte en el teléfono	Prueba funcional; sesión independiente de la PC
Imagen estilizada	Captura con personajes de caricature	YOLO: 0 objetos al 35 %; BLIP: descripción genérica de la pantalla	Limitación de dominio documentada




Figura 4. Prueba remota con Gradio Live: carga y resultado desde un teléfono. Cada navegador conserva su propia sesión.

6. Casos de falla documentados

Los siguientes casos se documentaron durante el desarrollo o se derivan directamente de los límites implementados. La columna final distingue entre una mitigación ya aplicada y una mejora futura.

#	Entrada específica	Qué salió mal	Causa	Acción aplicada o propuesta
1	Botón Analizar sin imagen ni audio	La interfaz no genera reporte y la terminal registra una excepción de Gradio.	Falta de entrada válida.	Implementado: mensaje claro y corte temprano; futuro: evitar imprimir traceback esperado.
2	MP3 musical de 19.6 s	Whisper produjo letras/frases que no pudieron verificarse.	La música y el canto enmascaran el habla; ASR no es un transcriptor musical.	Implementado: AST detecta música dominante y agrega advertencia; usar voz limpia.
3	Captura con personajes de caricatura, umbral 35 %	YOLO no detectó objetos; BLIP describió solo una pantalla con caricaturas.	Cambio de dominio y clases limitadas a COCO.	Implementado: se informa 0 detecciones; futuro: OCR, detector open-vocabulary o modelo ajustado.
4	Audio mayor a 30 s	Solo se analiza el primer tramo y se pierde el resto.	Límite deliberado de duración para tiempo y memoria.	Implementado: indicador de truncamiento; futuro: procesamiento completo por chunks.
5	Primera ejecución después de limpiar la caché	La respuesta tarda por la descarga y carga de varios checkpoints.	Inicialización fría; los modelos suman más de 1.7 GB de archivos.	Implementado: caché y reutilización; precalentar antes del Demo Day.
6	Resultado generado desde el teléfono	La PC no mostró automáticamente lo procesado en el teléfono.	Sesiones Gradio independientes por navegador.	Comportamiento esperado; futuro: sesión compartida o persistencia con identificador.
7	Cerrar/recargar navegador durante una petición	WinError 10054 en la terminal.	El cliente remoto cerró la conexión TCP.	Recargar y repetir; futuro: manejo explícito de cancelación y logging menos ruidoso.
8	Archivo de audio vacío o corrupto	Librosa no obtiene forma de onda y el pipeline no puede continuar.	Decodificación fallida o formato no soportado.	Implementado: excepción descriptiva; futuro: validación MIME y conversión segura con FFmpeg.
9	Dos usuarios ejecutan inferencia pesada al mismo tiempo	Riesgo de saturar VRAM o degradar latencia.	Los cinco modelos permanecen en memoria.	Implementado: concurrencia 1 y cola máxima 20; futuro: workers separados o descarga selectiva.

7. Ética, guardrails y riesgos pendientes

MediaScope produce estimaciones y no verifica la verdad de una escena ni la identidad de las personas. Por ello, su uso apropiado es descriptivo y académico; no debe emplearse como evidencia única en decisiones legales, laborales, médicas, de seguridad o reputacionales.

Escenario de mal uso	Riesgo	Guardrail actual	Problema no resuelto
Vigilancia o perfilamiento sin consentimiento	Analizar fotos o audios privados para inferir conducta o presencia de personas.	YOLO solo reporta la clase persona y no realiza reconocimiento facial; el reporte incluye una advertencia de verificación.	No existe autenticación, consentimiento verificable, borrado automático ni control de quién usa un enlace público.
Acusación falsa por una transcripción o caption incorrectos	Presentar como hecho una frase alucinada por Whisper o una escena mal descrita por BLIP.	Se muestran modelos, confianzas, tiempos y evidencia separada; la música dominante genera una advertencia.	No hay verificador de hechos ni humano obligatorio; el usuario todavía puede ignorar las advertencias.
Narración engañosa o desinformación	Convertir un reporte erróneo en una voz convincente y compartirlo fuera de contexto.	La narración se deriva del reporte estructurado, usa una voz fija y la interfaz declara que es una estimación automática.	El WAV no tiene marca de agua ni metadatos firmados que demuestren su origen.
Exposición de datos personales	Subir rostros, conversaciones o información sensible a un enlace público temporal.	La inferencia se ejecuta localmente y los modelos no requieren APIs externas una vez almacenados en caché.	El túnel público no sustituye controles de acceso; los archivos temporales y outputs requieren una política de retención y limpieza.

7.1 Principios operativos recomendados

- Solicitar consentimiento antes de analizar material de terceros y evitar datos sensibles durante demostraciones públicas.
- Conservar la evidencia por modelo y no sustituirla por una conclusión única; la fusión debe ser explicable.
- Revisar manualmente la transcripción, especialmente cuando AST identifica música, ruido o canto.
- Cerrar el share link después de la demostración y eliminar outputs que ya no sean necesarios.
- Respetar las licencias de los checkpoints; MMS-TTS spa es CC BY-NC 4.0 y no debe asumirse apto para uso comercial.

8A. Reproducibilidad Versión .py

8.1 Semillas y determinismo

La síntesis de voz fija la semilla como 42 + índice del fragmento mediante `torch.manual_seed()` y `torch.cuda.manual_seed_all()`. BLIP usa beam search sin muestreo; YOLO, Whisper y AST se ejecutan en modo evaluación/inferencia. Esto reduce la variación, aunque no garantiza igualdad bit a bit entre distintas GPU, versiones de CUDA o kernels. Para una ejecución global controlada se recomienda inicializar también random y NumPy al arrancar la aplicación.

```
SEED = 42
import random, numpy as np, torch
random.seed(SEED)
np.random.seed(SEED)
torch.manual_seed(SEED)
if torch.cuda.is_available():
    torch.cuda.manual_seed_all(SEED)
```

8.2 Dependencias

El proyecto incluye `requirements.txt` con rangos compatibles. El entorno validado utilizó las versiones siguientes; para conservar una réplica exacta debe generarse adicionalmente `requirements-lock.txt` con pip freeze después de la instalación.

Paquete	Versión validada / restricción
Python	3.12
Torch	2.14.0+cu130
Torchvision	0.29.0+cu130
Gradio	6.17.3 (requirements: >=5.49,<7)
Ultralytics	8.4.159 (requirements: >=8.4,<9)
Transformers	4.57.6 (requirements: >=4.49,<5)
Pillow	12.3.0 (requirements: >=10,<13)
Librosa	0.11.0
Soundfile	0.14.0 (requirements: >=0.13,<1)
Scipy	>=1.13,<2

8.3 Instalación desde cero en Windows

1. Instalar Python 3.12 y un controlador NVIDIA compatible con CUDA 13.0; si no existe GPU, omitir la instalación CUDA y utilizar PyTorch CPU.
2. Descomprimir MediaScope_Etapa7 en C:\project_final_m6_ia y abrir PowerShell en esa carpeta.
3. Crear y activar un entorno virtual.
4. Instalar PyTorch CUDA y después las dependencias del proyecto.
5. Verificar CUDA y ejecutar `app.py`. La primera inferencia descargará BLIP, Whisper, AST y MMS-TTS; YOLO11n se descarga automáticamente si falta y existe conexión.
6. Abrir <http://127.0.0.1:7860>. Para una URL pública temporal, establecer `GRADIO_SHARE=true` antes de iniciar.

```
cd C:\project_final_m6_ia\MediaScope_Etapa7
py -3.12 -m venv .venv
Set-ExecutionPolicy -Scope Process -ExecutionPolicy RemoteSigned
& ".\venv\Scripts\Activate.ps1"
python -m pip install --upgrade pip
python -m pip install torch==2.14.0 torchvision==0.29.0 --index-url
https://download.pytorch.org/whl/cu130
python -m pip install -r requirements.txt
python -c "import torch; print(torch.__version__); print(torch.cuda.is_available())"
python app.py
```

8.4 Protocolo mínimo de verificación

- Ejecutar el caso imagen + audio y confirmar cinco modelos, narración y reporte .md.
- Probar solo imagen, solo audio y sin entradas para validar las rutas condicionales.
- Ejecutar una inferencia de calentamiento antes de medir tiempos.
- Registrar versión de paquetes, GPU, umbral, idioma y hashes de los archivos de prueba.
- Si se requiere medir VRAM real por modelo, reiniciar estadísticas con `torch.cuda.reset_peak_memory_stats()` y registrar `torch.cuda.max_memory_allocated()`.

8B. Reproducibilidad Versión ipynb para COLAB

Ejecución de MediaScope en Google Colab

MediaScope también puede ejecutarse desde Google Colab mediante el notebook `MediaScope.ipynb`. Esta versión conserva los módulos originales del proyecto y automatiza la configuración del entorno, la instalación de dependencias, la extracción del proyecto, la verificación de los modelos y el lanzamiento de la interfaz Gradio.

📁 Paso 1. Descargar desde Git-Hub y Guardar el proyecto en Google Drive

📄 Paso 2. Abrir el notebook en Google Colab y activar el TOKEN

⚡ Paso 3. Activar la GPU T4

1. Seleccionar **Entorno de ejecución**.
2. Presionar **Cambiar tipo de entorno de ejecución**.
3. Elegir **T4 GPU** como acelerador de hardware.
4. Presionar **Guardar**.

La GPU es recomendable porque MediaScope utiliza varios modelos de inteligencia artificial. Aunque el proyecto puede funcionar con CPU, el tiempo de procesamiento sería considerablemente mayor.

📄 Paso 4. Verificar el entorno de ejecución

Ejecutar la celda correspondiente a:

```
1. Check the Colab runtime
```

La salida esperada debe ser similar a:

```
Device: cuda  
GPU: Tesla T4  
Total VRAM: 14.75 GB
```

Si aparece la siguiente salida:

```
Device: cpu
```

se debe detener la ejecución, activar la GPU T4 y volver a ejecutar la celda.

📦 Paso 5. Instalar las dependencias

Ejecutar la celda:

```
2. Install the dependencies
```

Esta celda instala las bibliotecas necesarias para utilizar:

-
- YOLO11n.
 - BLIP.
 - Whisper.
 - AST.
 - MMS-TTS.
 - Gradio.
 - Librosa.
 - SoundFile.

El notebook no reinstala PyTorch, ya que Colab proporciona una versión configurada para su entorno CUDA.

La salida esperada es:

```
Dependencies installed.
```

Si Colab solicita reiniciar la sesión, se debe aceptar el reinicio y volver a ejecutar las celdas desde el inicio.

Paso 6. Montar Google Drive

1. Seleccionar la cuenta de Google.
2. Autorizar el acceso a Drive.
3. Esperar el mensaje de confirmación.

La salida esperada es:

```
Google Drive mounted.
```

El montaje permite leer el proyecto y guardar permanentemente los resultados generados.

Paso 7. Localizar el archivo ZIP

Ejecutar la celda:

```
4. Locate or upload the project ZIP
```

Solo debe subirse el archivo ZIP completo. No es necesario descomprimirlo previamente.

Paso 8. Extraer y configurar el proyecto

Ejecutar la celda:

```
5. Extract and configure MediaScope
```

La celda realiza automáticamente las siguientes acciones:

- Crea una carpeta temporal para MediaScope.
- Extrae el contenido del archivo ZIP.
- Localiza la carpeta `MediaScope_Etapa7`.
- Configura las rutas de Python.
- Crea la carpeta de resultados.

-
- Verifica la existencia de los módulos principales.

La salida correcta debe finalizar con:

```
All required modules were found.
```

El ZIP original almacenado en Google Drive no se modifica.

✓ Paso 9. Verificar los módulos del pipeline

Ejecutar la celda:

```
6. Import and verify the pipeline
```

Esta comprobación importa los componentes principales sin cargar todavía todos los pesos de los modelos.

La salida muestra:

- Versión de Gradio.
- Versión de Transformers.
- Versión de Ultralytics.
- Modelo de detección.
- Modelo de descripción visual.
- Modelo de transcripción.
- Modelo de clasificación acústica.
- Modelo de síntesis de voz.

La comprobación debe terminar con:

```
Pipeline modules imported correctly.
```

📄 Paso 10. Ejecutar opcionalmente la comparación de modelos YOLO

El notebook incluye una comparación opcional entre:

- YOLO11n.
- YOLO11s.
- YOLO11m.

Para omitir esta prueba, se debe conservar:

```
RUN_YOLO_COMPARISON = False
```

Esta opción es recomendable durante la primera ejecución de la aplicación.

Para realizar la comparación, se debe cambiar a:

```
RUN_YOLO_COMPARISON = True
```

Después:

1. Ejecutar la celda.
2. Subir una imagen JPG, PNG o WEBP.
3. Esperar la descarga de los tres modelos.
4. Revisar la tabla comparativa.
5. Guardar los resultados obtenidos.

La tabla incluye:

- Cantidad de detecciones.
- Confianza promedio.
- Tiempo promedio.
- Tiempo mínimo.
- Tiempo máximo.
- Memoria máxima de GPU.

Los resultados se guardan en:

yolo_comparison.csv

Para una comparación más sólida, la prueba debe repetirse con imágenes de personas, salones, calles, objetos pequeños, poca iluminación y contenido estilizado.

Paso 11. Iniciar la interfaz de MediaScope

Ejecutar la celda:

```
8. Launch the MediaScope interface
```

Colab generará un enlace público de Gradio parecido al siguiente:

```
https://xxxxxxx.gradio.live
```

El enlace debe abrirse en una nueva pestaña del navegador.

La celda debe permanecer en ejecución mientras se utiliza la aplicación. Si se detiene la celda, el enlace dejará de funcionar.

La primera inferencia puede tardar varios minutos porque se descargan y cargan los pesos de los modelos.

Paso 12. Realizar una prueba visual

Para probar únicamente la rama visual:

1. Subir una imagen.
2. No cargar audio.
3. Mantener el umbral de confianza en 0.35.
4. Seleccionar el reporte **Detallado**.
5. Presionar **Analizar y narrar**.

La aplicación debe mostrar:

- Imagen anotada.
- Objetos detectados por YOLO11n.
- Cantidad de objetos.
- Confianza promedio.
- Descripción de la escena generada por BLIP.
- Reporte visual parcial.
- Narración en español.

Paso 13. Realizar una prueba auditiva

Para probar únicamente la rama auditiva:

1. Subir o grabar un audio.
2. No cargar ninguna imagen.
3. Utilizar un audio de máximo 30 segundos.
4. Seleccionar el idioma automático, español o inglés.
5. Presionar **Analizar y narrar**.

La aplicación debe mostrar:

- Transcripción generada por Whisper.
- Eventos acústicos identificados por AST.
- Intervalos de tiempo.
- Confianza de cada sonido.
- Reporte auditivo parcial.
- Narración en español.

Paso 14. Realizar una prueba multimodal

Para probar el pipeline completo:

1. Subir una imagen.
2. Subir o grabar un audio.
3. Seleccionar el reporte **Detallado**.
4. Mantener el umbral inicial en 0.35.
5. Presionar **Analizar y narrar**.

MediaScope ejecutará:

Imagen → YOLO11n + BLIP
Audio → Whisper + AST
Resultados → Fusión multimodal
Reporte → MMS-TTS + Markdown
Salidas → Interfaz Gradio

La aplicación debe generar evidencia visual y auditiva, un reporte integrado, una narración y un archivo Markdown descargable.

Paso 15. Verificar las rutas condicionales

Se recomienda ejecutar las siguientes pruebas:

Prueba	Imagen	Audio	Resultado esperado
Solo imagen	Sí	No	Reporte visual y narración
Solo audio	No	Sí	Reporte auditivo y narración
Multimodal	Sí	Sí	Reporte integrado y narración
Sin entradas	No	No	Mensaje de validación

La prueba sin entradas debe mostrar un mensaje indicando que se debe cargar al menos una imagen o un audio.

Paso 16. Revisar las salidas

La interfaz organiza los resultados en las siguientes pestañas:

- **Análisis visual:** imagen anotada, detecciones y descripción.
- **Análisis auditivo:** transcripción y sonidos detectados.
- **Reporte multimodal:** resumen integrado y narración.
- **Detalles técnicos:** modelos, dispositivos y tiempos.
- **Acerca del pipeline:** arquitectura y requisitos cubiertos.

Las predicciones son probabilísticas y deben verificarse antes de utilizarlas en decisiones importantes.

Paso 17. Guardar los resultados en Google Drive

Después de finalizar las pruebas, ejecutar la celda:

```
9. Save the outputs to Google Drive
```

Los resultados se copian en:

```
MyDrive/TAE_IA_M6/MediaScope_outputs/
```

Dentro de esta carpeta se crea una subcarpeta identificada con la fecha y hora de ejecución.

Los archivos pueden incluir:

- Narraciones WAV.
- Reportes Markdown.
- Resultados de la comparación de YOLO.
- Archivos técnicos generados por la aplicación.

Paso 18. Finalizar la sesión

Después de guardar los resultados:

-
1. Cerrar el enlace público de Gradio.
 2. Detener la celda que ejecuta la interfaz.
 3. Seleccionar **Entorno de ejecución** → **Desconectar y eliminar entorno de ejecución**.

Los archivos temporales almacenados en `/content` se eliminan cuando termina la sesión. El ZIP original y los resultados copiados a Google Drive permanecen guardados.

Recomendaciones de ejecución

- Utilizar una GPU T4.
- Procesar audios de máximo 30 segundos.
- Ejecutar una inferencia inicial de calentamiento antes de medir tiempos.
- Mantener una sola solicitud activa.
- No ejecutar simultáneamente la comparación de YOLO y la interfaz.
- Registrar la GPU, el umbral y las versiones de los paquetes.
- Verificar manualmente las detecciones y transcripciones.
- Cerrar el enlace público después de la demostración.
- No utilizar las predicciones automáticas como evidencia única para decisiones importantes.

9. Pruebas

9.1 Reporte comparativo de pruebas multimodales

Se realizaron cinco pruebas completas de MediaScope utilizando una GPU Tesla T4. En todas las ejecuciones se procesaron simultáneamente una imagen y un audio mediante YOLO11n, BLIP, Whisper, AST y MMS-TTS. Las pruebas permitieron observar el comportamiento del sistema con voz, ladridos, llanto, personas, animales y escenas con distintos niveles de dificultad.

Tabla 1. Resultados generales de las pruebas

Prueba	Umbral	Resolución de imagen	Resultado de YOLO11n	Descripción de BLIP	Resultado de Whisper	Resultado de AST	Evaluación
1. Tráfico y voz	35 %	1254 × 1254	7 objetos: 2 bicicletas, 1 autobús, 1 automóvil, 1 motocicleta, 1 persona y 1 semáforo	2 “A blue sky with white clouds.”	Reconoció una frase sobre un modelo de inteligencia artificial, pero mezcló español e inglés	Habla 91 % y voz femenina 1 %	YOLO y AST funcionaron correctamente. BLIP describió solamente el cielo y no representó los objetos principales. Whisper conservó la idea general, pero cometió errores de idioma.
2. Perro y ladridos	75 %	365 × 547	1 perro	“A black and white dog sitting in the grass.”	Interpretó los ladridos como “¡Bah!”	Perro 31 %, animal 29 % y ladrido 16 %	YOLO, BLIP y AST fueron consistentes. Whisper no es adecuado para interpretar sonidos de animales porque está diseñado para reconocer habla.
3. Caricatura y llanto	75 %	332 × 511	Sin detecciones	“Yoo aveiras and the pandas movie poster.”	Generó una secuencia extensa de letras “a”	Llanto infantil 90 %, llanto o sollozo 5 % y gemido 4 %	AST identificó correctamente el llanto. YOLO no reconoció objetos por el contenido estilizado y el umbral alto. BLIP produjo una descripción poco confiable y Whisper confundió el llanto con una vocal sostenida.
4. Caricatura y llanto	35 %	332 × 511	Sin detecciones	“Yoo aveiras and the pandas movie poster.”	Generó una secuencia extensa de “AH”	Llanto infantil 90 %, llanto o sollozo 5 % y gemido 4 %	Reducir el umbral de 75 % a 35 % no produjo detecciones. Esto indica que la falla está relacionada con el dominio de la imagen y las clases de

					COCO, no solamente con el umbral.	
					YOLO y Whisper obtuvieron resultados adecuados. BLIP entendió la escena general, pero confundió uno de los perros con un gato.	
5.				Reconoció		
Personas,		4 objetos:	1 “A woman	correctamente	la Habla	91 %
perros y	35 %	× banco,	2 standing next	frase en inglés y	voz	
voz	1254	perros y	1 to a dog and	sobre	femenina	1
	1254	persona	a cat.”	procesamiento de	%	
				señales de audio		

Tabla 2. Comparación de tiempos de inferencia

Prueba	YOLO11n	BLIP	Whisper	AST	MMS-TTS	Tiempo acumulado de modelos
1. Tráfico y voz	1994.1 ms	1078.4 ms	990.7 ms	79.1 ms	1435.2 ms	5577.5 ms
2. Perro y ladridos	68.6 ms	609.0 ms	383.8 ms	30.2 ms	737.8 ms	1829.4 ms
3. Caricatura y llanto, 75 %	66.9 ms	544.7 ms	11019.2 ms	34.4 ms	722.2 ms	12387.4 ms
4. Caricatura y llanto, 35 %	18.4 ms	961.8 ms	9521.6 ms	35.9 ms	710.6 ms	11248.3 ms
5. Personas, perros y voz	113.0 ms	937.8 ms	539.5 ms	51.6 ms	567.1 ms	2209.0 ms

El tiempo acumulado corresponde a la suma de las inferencias reportadas por los cinco modelos. No incluye carga de archivos, validación, fusión, actualización de la interfaz ni transferencia mediante Gradio.

Tabla 3. Análisis por modelo

Modelo	Aciertos observados	Limitaciones observadas	Recomendación
YOLO11n	Detectó vehículos, personas, perros, bicicletas, banco y semáforo con tiempos bajos después de la primera ejecución	No detectó objetos en la imagen estilizada, incluso al reducir el umbral de 75 % a 35 %	Mantener YOLO11n para objetos COCO y considerar un detector open-vocabulary para caricaturas u objetos fuera de dominio
BLIP	Generó descripciones correctas para el perro y para la escena con una persona y animales	Omitió los objetos del tráfico, generó texto poco claro en la caricatura y confundió un perro con un gato	Mostrar siempre el caption como una descripción estimada y contrastarlo con las detecciones de YOLO
Whisper	Transcribió correctamente la voz inglesa y conservó parcialmente la idea de una frase bilingüe	Intentó convertir ladridos y llanto en palabras o vocales, generando textos sin valor semántico	No presentar la transcripción como confiable cuando AST detecte ladrido, llanto, música u otro sonido no verbal dominante
AST	Identificó correctamente habla, ladridos y llanto infantil	Algunas categorías relacionadas aparecen separadas, como perro, animal y ladrido	Consolidar categorías acústicas equivalentes en el reporte final
MMS-TTS	Generó narraciones en español para todas las pruebas	La narración se vuelve innecesariamente extensa cuando Whisper produce una secuencia repetitiva	Limitar repeticiones y limpiar la transcripción antes de enviarla al sintetizador

📌 **Tabla 4. Efecto del umbral en la imagen estilizada**

Configuración	Detecciones	Tiempo YOLO	Interpretación
Umbral de 75 %	0	66.9 ms	No hubo objetos con una confianza suficientemente alta
Umbral de 35 %	0	18.4 ms	Reducir el umbral no recuperó ninguna detección
Resultado	Sin cambio	No directamente comparable	La principal limitación es el cambio de dominio y no únicamente el umbral

★ **Hallazgos principales**

1. **La primera inferencia fue más lenta.** En la primera prueba, YOLO11n necesitó 1994.1 ms. En las ejecuciones posteriores utilizó entre 18.4 y 113.0 ms. Esto es consistente con el calentamiento inicial, la carga de pesos y la inicialización de CUDA.
2. **YOLO11n funcionó mejor con objetos reales pertenecientes a COCO.** El modelo detectó correctamente vehículos, personas, bicicletas y perros. Sin embargo, no obtuvo detecciones en una imagen estilizada.
3. **BLIP y YOLO ofrecieron información complementaria.** YOLO proporcionó clases, cantidades y localización. BLIP describió el contexto general, aunque algunas descripciones fueron incompletas o incorrectas.
4. **AST fue más apropiado que Whisper para sonidos no verbales.** AST reconoció ladridos y llanto infantil, mientras que Whisper intentó representarlos como palabras o vocales.
5. **Whisper presentó la mayor variación de tiempo.** Las transcripciones de voz necesitaron entre 383.8 y 990.7 ms. Los audios de llanto produjeron secuencias repetitivas y elevaron el tiempo hasta 11019.2 ms.
6. **El umbral no resolvió la falla de dominio.** La imagen estilizada produjo cero detecciones tanto con 75 % como con 35 %. Esto muestra que disminuir la confianza no garantiza mejores resultados cuando el contenido no pertenece al dominio de entrenamiento.
7. **La fusión multimodal permitió detectar resultados poco confiables.** Por ejemplo, cuando Whisper produjo una transcripción repetitiva, AST identificó que el sonido real correspondía a llanto infantil.

10. Conclusiones

10.1 Pruebas analizadas

Las cinco ejecuciones confirman que MediaScope completa el pipeline multimodal con imagen, audio, reporte y narración. El sistema obtuvo sus mejores resultados con fotografías reales y voz clara. YOLO11n mostró un buen equilibrio entre velocidad y detección después de la primera inferencia, mientras que AST fue especialmente útil para reconocer sonidos no verbales.

Las principales limitaciones aparecieron en imágenes estilizadas y audios sin habla. En estos casos, BLIP generó descripciones imprecisas y Whisper produjo transcripciones repetitivas. Por esta razón, el reporte final debe conservar la evidencia separada de cada modelo, mostrar las confianzas y advertir cuando los modelos visuales o auditivos no coincidan.

Como mejora futura, se recomienda incorporar un detector open-vocabulary, agregar una validación de repetición para Whisper y evitar que MMS-TTS narre transcripciones formadas principalmente por una sola letra o sonido.

10.2 Qué funcionó

Se construyó y validó un pipeline funcional de extremo a extremo con cinco modelos: dos de visión, dos de análisis auditivo y uno de síntesis. La aplicación procesa una o ambas modalidades, genera evidencia separada, fusiona los resultados sin depender de un LLM adicional, narra el reporte en español y permite descargar trazabilidad técnica. La RTX 4070 Laptop ejecutó todas las etapas con CUDA y el enlace público de Gradio fue probado desde un teléfono con datos móviles.

10.2 Qué no funcionó de forma perfecta

La transcripción de música no fue confiable; BLIP produjo captions en inglés y puede ser genérico; YOLO11n no reconoce bien contenido estilizado ni categorías fuera de COCO; la primera inferencia es más lenta; los resultados no se sincronizan entre sesiones de navegador; y el share link es temporal. También quedaron advertencias de deprecación que no impidieron la ejecución, pero deben revisarse al actualizar Transformers o Gradio.

10.3 Qué se haría diferente

En una segunda versión se congelarían todas las dependencias desde el inicio, se crearían pruebas automatizadas con un conjunto pequeño de imágenes y audios de referencia, se mediría VRAM y latencia con una metodología repetible, se añadiría traducción o captioning multilingüe, se procesaría audio largo por ventanas, se incorporaría OCR y detección open-vocabulary, y se desplegaría detrás de autenticación con una política explícita de retención. Solo después de medir la memoria se evaluaría paralelizar las ramas; en el prototipo se priorizó estabilidad con concurrencia uno.

Conclusión general

MediaScope demuestra de forma visible los requisitos académicos y, al mismo tiempo, documenta sus límites. Su principal valor no es afirmar que “comprende” una escena, sino organizar evidencia de varios modelos y entregarla de forma accesible, trazable y narrada.

11. Referencias

- [1] Ultralytics. YOLO11 — documentación oficial. <https://docs.ultralytics.com/models/yolo11/>
- [2] Salesforce. BLIP Image Captioning Base — model card. <https://huggingface.co/Salesforce/blip-image-captioning-base>
- [3] OpenAI. Whisper Base — model card. <https://huggingface.co/openai/whisper-base>
- [4] MIT/Hugging Face. AST fine-tuned on AudioSet — model card. <https://huggingface.co/MIT/ast-finetuned-audioset-10-10-0.4593>
- [5] Meta. MMS-TTS Spanish — model card y licencia. <https://huggingface.co/facebook/mms-tts-spa>
- [6] Gradio. Blocks y componentes de interfaz. <https://www.gradio.app/docs/gradio/blocks>
- [7] PyTorch. Reproducibility notes. <https://docs.pytorch.org/docs/stable/notes/randomness.html>
- [8] Hugging Face Transformers. BLIP, Whisper, AST y VITS. <https://huggingface.co/docs/transformers/>

Nota sobre las cifras de memoria

Los tamaños de archivo se basan en los checkpoints descargados y las fichas oficiales. Las cifras de VRAM son estimaciones para inferencia y deben confirmarse con medición local si se utilizarán como benchmark. El hecho de que la aplicación haya funcionado en una RTX 4070 Laptop de 8 GB confirma compatibilidad con ese entorno, no un consumo fijo para cualquier equipo.